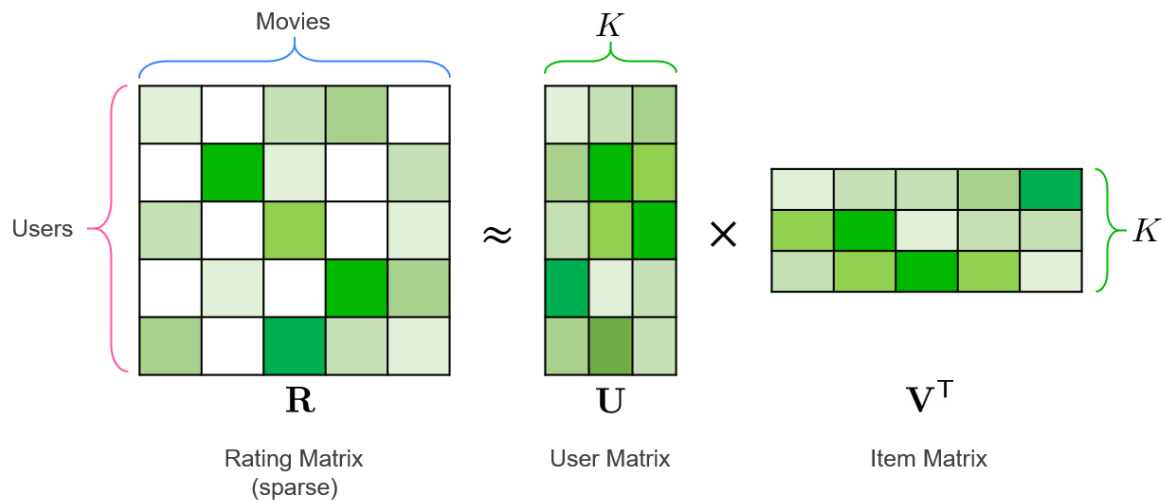


Matrix Factorization Recommender System

1. 소개


1.1. Matrix Factorization

- Matrix Factorization(MF)은 추천 시스템의 협업필터링(CF, Collaborative Filtering) 기법 중 Latent Factor 모델에 해당함
- Latent Factor 모델은 아래의 그림과 같이 User와 Item을 K -차원을 가지는 latent vector로 표현하는 모델임
- 그 중 MF는 User와 Item을 K -차원을 가지는 동일한 latent space에 매핑함



1.2. Singular Vector Decomposition(SVD)


- MF 모델에서 가장 일반적인 방법 중 하나는 SVD(특이값 분해)가 있음
- 하지만, SVD는 데이터의 수가 커질수록 연산 속도가 매우 느려지는 문제가 발생함
- 또한, 대부분의 Rating Matrix(**R**)가 매우 sparse하기 때문에 성능이 좋지 않음



2. 모델 구현

2.1. Probabilistic Matrix Factorization(PMF)

- Rating Matrix \mathbf{R} 의 분해값에 해당하는 User Matrix \mathbf{U} 와 Item Matrix \mathbf{V} 를 가우스 분포 $\mathcal{N}(0, \sigma^2)$ 를 사용하여 추정하는 모델임



- \mathbf{U} , \mathbf{V} 를 학습하기 위해, SGD(Stochastic Gradient Descent) + Momentum(β)을 사용함
- \mathbf{U} 을 SGD + Momentum을 사용하여 학습하는 방법은 아래의 수식과 같음

$$\mathbf{E} = \mathbf{R} - \mathbf{U}^T \mathbf{V}$$

$$\mathbf{M} \leftarrow \beta \mathbf{M} - \eta \frac{\partial \mathbf{E}}{\partial \mathbf{U}}$$

$$\mathbf{U} \leftarrow \mathbf{U} + \mathbf{M}$$

- 추정하고자하는 $\hat{\mathbf{R}}_{ij}$ 은 아래의 식과 같이 계산할 수 있는데, 이 때 μ 는 전체 rating의 평균을 의미함

$$\hat{\mathbf{R}}_{ij} = \mu + \mathbf{U}_i^T \mathbf{V}_j$$


2.2. PMF + Bias terms (BiasPMF)

- bias를 추가하여 각 User 및 Item 간의 특성을 반영해 줌
- 2.1에서 살펴본 PMF 모델에 \mathbf{U}_i 에 해당하는 bias \mathbf{b}_{U_i} 와 \mathbf{V}_j 의 bias \mathbf{b}_{V_j} 를 추가해 줌

$$\hat{\mathbf{R}}_{ij} = \mu + \mathbf{U}_i^T \mathbf{V}_j + \mathbf{b}_{U_i} + \mathbf{b}_{V_j}$$

2.3. BiasPMF + User/Item Specific Ratings (AddPMF)

- 2.2에서 살펴본 BiasPMF 모델에 각 User 및 Item 간의 특성을 더 반영해주기 위해 User 및 Item에 대한 content-based 정보를 반영해 줌
- 각 User들이 과거에 부여한 rating의 평균을 User별로 따로 사용함 $\rightarrow \mu_{U_i}$
- 마찬가지로, Item들이 과거에 부여받은 rating의 평균을 Item별로 따로 사용함 $\rightarrow \mu_{V_j}$
- 이러한 User 및 Item의 specific rating을 아래와 같이 가중평균하여 적용해줌



3. 실험 및 결과

3.1. MovieLens-20m 데이터셋

- MovieLens 데이터셋은 추천 시스템 분야에서 대표적인 benchmark 데이터셋에 해당함
- 그 중 MovieLens-20m는 138,000 명의 사용자가 27,000개의 영화에 대해 2천만개의 rating으로 구성되어 있음

3.2. 실험 환경 구성

- 과제1 및 과제2를 아래의 표와 같이 구성하여 학습 및 평가를 진행함

	과제 1 (DS1)	과제 2 (DS2)
학습 데이터	2005-01-01 ~ 2008-12-31 (5,187,587)	~ 2013-12-31 (19,152,913)
평가 데이터	2009-01-01 ~ 2009-12-31 (930,093)	2014-01-01 ~ (847,350)

- PMF, BiasPMF, AddPMF 3 가지 모델에 대해 아래의 표와 같이 동일하게 설정해 줌

하이퍼파라미터	값	설명
seed	42	NumPy random seed
epoch	[20, 30]	학습 횟수
batch_size	100,000	배치 사이즈
features	[3, 5, 10, 50, 100]	latent vector 차원 수
reg	[0.01, 0.02, 0.04 , 0.05, 0.1]	regularization 파라미터
momentum	[0.8, 0.9]	모멘텀 계수
lr	[0.0001, 0.0005 , 0.001, 0.005]	learning rate
alpha	[0.4(DS1), 0.5(DS2) , 0.6]	AddPMF에서 사용하는 User/Item specific rating 가중치

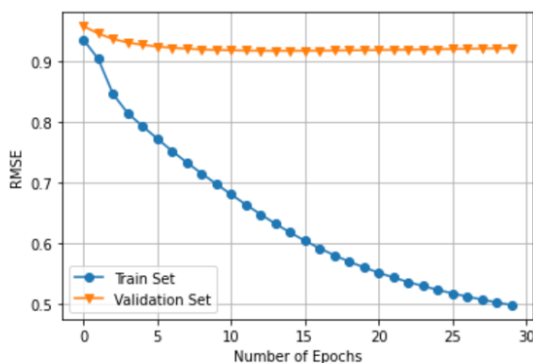
3.3. 결과

- 각 모델의 평가 데이터에 대한 실험 결과는 아래의 표와 같음

모델	DS1-RMSE	DS2-RMSE
PMF	0.916761	0.954441
BiasPMF	0.916812	0.954441
AddPMF	0.910013	0.950999

- 위의 표에서 확인할 수 있듯이, User 및 Item의 specific rating을 적용한 모델인 AddPMF가 DS1과 DS2의 데이터셋에 대해 성능이 가장 높게 나타남
- 위의 결과를 통해, User 및 Item에 대한 content-based 정보가 성능에 유의미하다는 것을 확인할 수 있음
- PMF와 BiasPMF의 결과를 비교해 보았을 때, U_i 에 해당하는 bias b_{U_i} 와 V_j 의 bias b_{V_j} 의 영향이 거의 없다는 것을 확인할 수 있음
- 하지만 아래의 그림과 같이 학습 데이터와 평가 데이터 간의 성능 차이가 매우 크며, 학습이 진행될수록 오버피팅이 되는 문제가 발생함

DS1 결과



DS2 결과

